

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



DATA REPORT

**Đề tài: Xây dựng hệ thống Image Captioning
tiếng Việt hỗ trợ người khiếm thị trong đời
sống hàng ngày**

Giảng viên hướng dẫn: TS. Bùi Tiên Lên

ThS. Lê Nhật Nam

ThS. Võ Nhật Tân

Sinh viên: Phạm Khánh Linh MSSV: 23127083

Võ Trung Hiếu MSSV: 23127190

Nguyễn Thành Lợi MSSV: 23127408

Lê Quốc Thiện MSSV: 23127481

Phạm Quang Thịnh MSSV: 23127485

Lớp: 23KHDL1

THÀNH PHỐ HỒ CHÍ MINH, 16 THÁNG 04 2026

Mục lục

1	Giới thiệu bài toán	3
2	Nguồn dữ liệu	3
3	Phương pháp thu thập	4
3.1	Quy trình thực hiện từng bước	4
3.2	Công cụ sử dụng	5
3.3	Định dạng lưu trữ	5
4	Quy trình làm sạch và tiền xử lý dữ liệu	6
4.1	Cấu trúc lưu trữ dữ liệu	6
4.2	Tiền xử lý dữ liệu hình ảnh	7
4.3	Tiền xử lý chú thích dạng phân cấp (JSON)	7
4.4	Kiểm soát và đảm bảo chất lượng dữ liệu	8
5	Khám phá và Phân tích dữ liệu (EDA)	9
5.1	Phân bố bối cảnh và Đặc trưng độ dài chú thích	9
5.2	Phân tích đặc trưng hình học (Geometry Analysis)	11
5.3	Phân tích đặc trưng ngôn ngữ định hướng	12
5.3.1	Phân tích vốn từ vựng theo từng bối cảnh cụ thể (Word Cloud) .	12
5.3.2	Phân tích cấu trúc cụm từ định hướng (Bigram Analysis)	14
5.3.3	Sự liên kết giữa cấu trúc cụm từ và đặc trưng bối cảnh	16
5.4	Phân tích đặc trưng thị giác (Visual Analysis)	18
5.5	Trực quan hóa mẫu dữ liệu (Qualitative Preview)	19
	Lời cảm ơn	21
	Tài liệu tham khảo	22

1 Giới thiệu bài toán

Tên đề tài: Xây dựng hệ thống Image Captioning tiếng Việt hỗ trợ người khiếm thị trong đời sống hàng ngày

Bài toán trọng tâm của đề án là sinh mô tả hình ảnh (**Image Captioning**) bằng tiếng Việt. Hệ thống được thiết kế để thực hiện quy trình xử lý từ hình ảnh sang ngôn ngữ và âm thanh, hướng tới việc hỗ trợ người khiếm thị:

- **Đầu vào:** Một hình ảnh tĩnh được cung cấp từ thiết bị (ảnh chụp thực tế).
- **Đầu ra:** Một câu mô tả *hoàn chỉnh, có ý nghĩa và đúng ngữ pháp* bằng tiếng Việt, tóm tắt các thực thể, hành động và mối quan hệ giữa chúng trong hình ảnh, kèm theo đó là hướng dẫn di chuyển cho người dùng, hoặc cảnh báo nếu có nguy hiểm.
- **Khả năng mở rộng:** Tích hợp module chuyển đổi văn bản thành giọng nói (*Text-to-Speech*) để phát ra thông tin mô tả bằng giọng nói tiếng Việt tự nhiên, giúp người khiếm thị tiếp nhận thông tin một cách thuận tiện nhất.

2 Nguồn dữ liệu

Dữ liệu của nhóm chủ yếu dựa trên dataset có sẵn, được sàng lọc thủ công lại để lấy số lượng ảnh nhỏ hơn:

- **Kaggle:** Ảnh giao thông đường phố Việt Nam và ảnh bối cảnh trong nhà
 - [za_traffic_2020](#)
 - [House Rooms & Streets Dataset](#)
- **COCO:** Ảnh các vật thể theo bối cảnh
 - [Ảnh phương tiện giao thông](#)

3 Phương pháp thu thập

3.1 Quy trình thực hiện từng bước

Quá trình xây dựng dataset được thực hiện theo quy trình 4 bước:

1. **Xác định chủ đề và tiêu chí lọc ảnh:** Nhóm thống nhất phân chia toàn bộ ảnh thu thập được thành 3 nhóm chủ đề chính – *Đường phố & Giao thông*, *Phương tiện công cộng*, và *Trong nhà* – cùng với các tiêu chí lọc về chất lượng ảnh.
2. **Thu thập và phân loại ảnh:** Ảnh được tải từ các bộ dữ liệu quốc tế (MS COCO, các bộ dữ liệu từ Kaggle). Sau khi tải về, tụi em tiến hành **phân loại** từng ảnh vào đúng thư mục chủ đề, đồng thời loại bỏ ảnh không phù hợp, trùng lặp hoặc kém chất lượng.
3. **Gán nhãn caption bằng NotebookLM:** Đây là giai đoạn quan trọng trong quy trình xây dựng dữ liệu. Nhóm sử dụng **Google NotebookLM** để gán nhãn caption tiếng Việt cho từng ảnh theo quy trình sau:
 - Thiết kế **3 prompt khác nhau** cho mỗi nhóm chủ đề, mỗi prompt hướng dẫn mô tả ảnh theo một góc nhìn của người khiếm thị (ví dụ: tập trung vào hướng di chuyển, mô tả vật cản, mô tả khoảng cách tương đối,...).
 - Lần lượt đưa từng ảnh vào **NotebookLM** cùng với prompt tương ứng để sinh ra 5 caption độc lập cho mỗi ảnh.
 - Kết quả là mỗi ảnh có **5 captions** đa dạng về cách diễn đạt nhưng đều mô tả đúng nội dung ảnh.
4. **Kiểm tra thủ công:** Sau khi gán nhãn tự động, các thành viên trong nhóm đọc lại và đối chiếu từng caption với ảnh gốc để xác nhận tính chính xác. Caption không liên quan đến nội dung ảnh hoặc có xuất hiện mặt người sẽ được gán nhãn bằng **Gemini** với prompt tương ứng.

3.2 Công cụ sử dụng

Công cụ	Mục đích sử dụng
Google NotebookLM	Gán nhãn caption tiếng Việt cho ảnh
Google Gemini	Gán nhãn lại caption cho các ảnh có xuất hiện khuôn mặt người (NotebookLM từ chối xử lý)
Google Drive	Chia sẻ và đồng bộ dữ liệu giữa các thành viên

Table 3.1: Công cụ sử dụng trong quá trình xây dựng dataset

3.3 Định dạng lưu trữ

Ảnh lưu dạng .jpg.

Caption lưu dạng JSON với cấu trúc:

```
{  
  "image": "00001.jpg",  
  "captions": [  
    {"caption_number": 0, "caption": "..."},  
    {"caption_number": 1, "caption": "..."},  
    ...  
  ]  
}
```

4 Qui trình làm sạch và tiền xử lý dữ liệu

4.1 Cấu trúc lưu trữ dữ liệu

Dữ liệu sau khi thu thập và làm sạch được tổ chức theo cấu trúc phân cấp để tối ưu hóa quá trình huấn luyện mô hình. Toàn bộ 8,000 hình ảnh và các nhãn chú thích tương ứng được lưu trữ như sau:

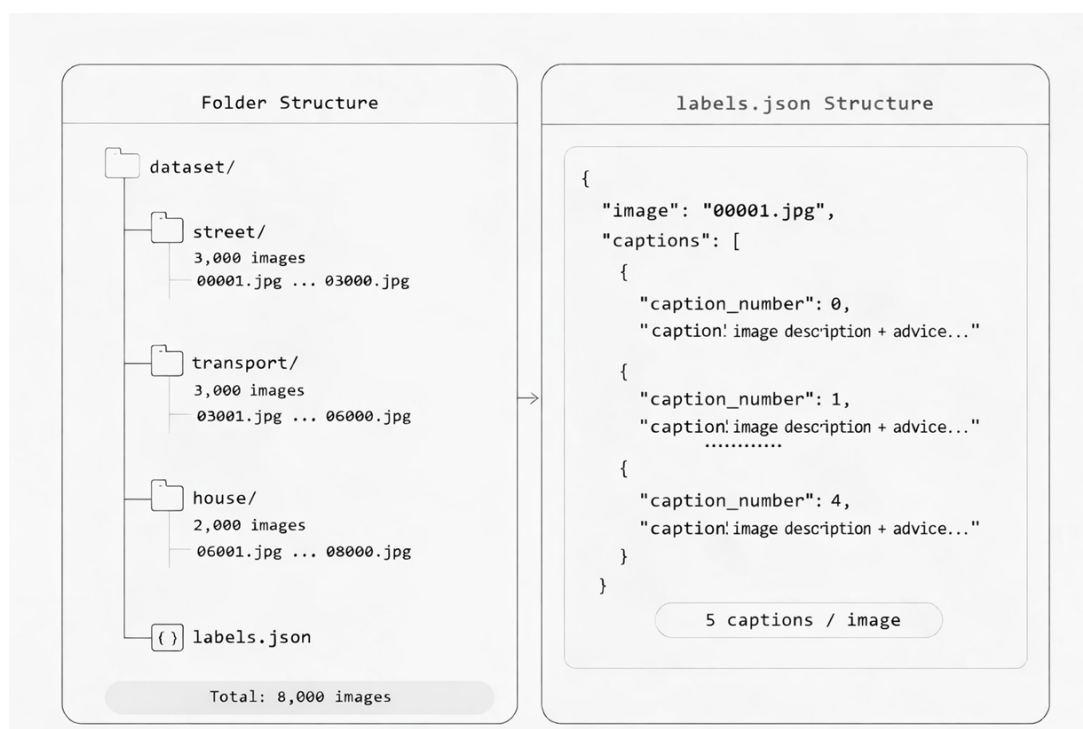


Figure 4.1: Sơ đồ cấu trúc thư mục và định dạng tệp tin nhãn labels.json

Tập dữ liệu được phân chia cụ thể:

- **Thư mục street/:** Chứa 3,000 ảnh bối cảnh đường phố (từ 00001.jpg đến 03000.jpg).
- **Thư mục transport/:** Chứa 3,000 ảnh về phương tiện giao thông (từ 03001.jpg đến 06000.jpg).
- **Thư mục house/:** Chứa 2,000 ảnh bối cảnh trong nhà (từ 06001.jpg đến 08000.jpg).
- **Tệp labels.json:** Lưu trữ dữ liệu dưới dạng phân cấp cho toàn bộ 8,000 hình ảnh. Mỗi tệp ảnh tương ứng với một danh sách gồm 5 captions khác nhau. Mỗi caption bao gồm phần mô tả các thực thể và lời khuyên di chuyển an toàn cho người khiếm thị.

Để đảm bảo chất lượng đầu vào cho mô hình, nhóm tiến hành quy trình tiền xử lý tập trung vào hai loại dữ liệu chính:

Dữ liệu hình ảnh (JPG)

Dữ liệu chú thích dạng phân cách (JSON)

4.2 Tiền xử lý dữ liệu hình ảnh

Quy trình tiền xử lý hình ảnh được giảm thiểu nhiều và chuẩn hóa định dạng đầu vào cho các mô hình:

- **Loại bỏ nhiễu (noise):** Loại bỏ các hình ảnh bị lỗi hiển thị, ảnh quá tối (độ sáng trung bình < 30) hoặc quá sáng (> 230) để đảm bảo có thể sinh ra captions hiệu quả. Lọc những ảnh đúng rõ ràng, đúng chủ đề và giống góc nhìn của 1 người.
- **Loại bỏ trùng lặp (duplicates):** Kiểm tra thủ công để phát hiện ảnh trùng nội dung dù khác tên file.
- **Chuẩn hoá và biến đổi dữ liệu:** Đồng nhất định dạng .jpg và kích thước chuẩn 224×224 px cho toàn bộ ảnh.
- **Định danh tệp tin:** Tiến hành đổi tên ảnh theo quy tắc chuẩn ONNNN.jpg để thuận tiện cho việc truy vấn và quản lý dữ liệu.
- **Kiểm tra nhất quán của dữ liệu:** Đảm bảo tất cả hình ảnh thống nhất định dạng .jpg và kiểm soát dung lượng mỗi tệp dưới 1.5 MB để tối ưu hóa tốc độ nạp dữ liệu khi huấn luyện.
- **Kiểm tra tính đầy đủ của ảnh xạ:** Xác nhận toàn bộ hình ảnh thuộc ba nhóm (*street, transport, house*) đều được gán nhãn đầy đủ với 5 captions cho mỗi tệp ảnh.

4.3 Tiền xử lý chú thích dạng phân cách (JSON)

Dữ liệu chú thích trong tệp JSON được xử lý để tăng tính nhất quán và giảm độ phức tạp cho quá trình học ngôn ngữ của mô hình:

- **Loại bỏ nhiễu (noise):** Tiến hành rà soát và loại bỏ các bản chú thích không đáp ứng đủ ba tiêu chí cốt lõi: mô tả ngữ cảnh, xác định vị trí thực thể và đưa ra lời khuyên an toàn. Các mẫu không đạt yêu cầu sẽ được thực hiện gán nhãn lại để đảm bảo chất lượng thông tin chỉ dẫn cho người khiếm thị.

- **Loại bỏ trùng lặp (duplicates):** Phát hiện và loại bỏ các câu chú thích có nội dung trùng lặp hoàn toàn trong cùng một tệp ảnh. Quy trình này đảm bảo tính đa dạng cho mỗi ảnh. Mỗi ảnh cần phải có 5 captions khác nhau.
- **Loại bỏ hoặc xử lý dữ liệu thiếu (missing values):** Đối với các hình ảnh có số lượng chú thích ít hơn 5, nhóm thực hiện bổ sung nhãn thông qua các công cụ (Gemini/NotebookLM) và kiểm định thủ công để đạt đủ số lượng quy định.
- **Chuẩn hoá caption:** Thực hiện chuyển đổi tất cả ký tự trong caption đều viết thường và kết thúc không có dấu chấm. Kiểm tra caption có chứa ký tự tiếng Việt có dấu (loại bỏ nếu không có dấu).
- **Kiểm tra nhất quán của dữ liệu:** Đảm bảo 5 caption của mỗi ảnh được thực hiện theo prompt mong muốn (mô tả ảnh + lời khuyên).

4.4 Kiểm soát và đảm bảo chất lượng dữ liệu

Để đảm bảo mô hình huấn luyện đạt độ tin cậy cao nhất cho người khiếm thị, nhóm thiết lập quy trình kiểm soát chất lượng dữ liệu qua nhiều bước kiểm chứng:

- **Tiêu chí dữ liệu đạt chuẩn:**
 - Nội dung caption phải phản ánh đúng thực tế các vật thể và hành động trong ảnh, không có hiện tượng ảo giác (hallucination) hay tự bịa ra nội dung.
 - Phải bao gồm đầy đủ hai thành phần cốt lõi là mô tả khách quan và chỉ dẫn an toàn theo cấu trúc Prompt đã thiết lập.
 - Độ dài mỗi caption được khống chế tối đa 256 ký tự để tối ưu hóa khả năng đọc của hệ thống Text-to-Speech và tiết kiệm tài nguyên tính toán (VRAM).
- **Quy trình kiểm định thủ công:** Nhóm phân công mỗi thành viên kiểm tra ngẫu nhiên ít nhất 200 mẫu dữ liệu trong mỗi nhóm chủ đề. Quá trình này tập trung vào việc phát hiện và sửa lỗi các câu mô tả quá lan man hoặc các cảnh báo không phù hợp với ngữ cảnh thực tế của người khiếm thị.
- **Kiểm soát tự động bằng Script Python:** Sử dụng công cụ tự động để rà soát toàn bộ 40,000 mẫu dữ liệu nhằm đảm bảo:
 - Xác thực sự tồn tại và tính hợp lệ của file ảnh tương ứng với đường dẫn trong file nhãn.

- Kiểm tra định dạng JSON để đảm bảo tính sẵn sàng cho quá trình nạp dữ liệu.
- Thống kê phân bố độ dài caption (ngắn nhất, trung bình, dài nhất) để đảm bảo dữ liệu không bị sai lệch.

5 Khám phá và Phân tích dữ liệu (EDA)

Quá trình khám phá dữ liệu (Exploratory Data Analysis) đóng vai trò quyết định trong việc hiểu rõ đặc trưng của 8,000 cặp dữ liệu ảnh-chú thích, từ đó đưa ra chiến lược huấn luyện mô hình sinh chú thích hỗ trợ người khiếm thị hiệu quả.

5.1 Phân bố bối cảnh và Đặc trưng độ dài chú thích

Để hiểu rõ cấu trúc của tập dữ liệu 8,000 ảnh phục vụ bài toán hỗ trợ người khiếm thị, nhóm thực hiện phân tích thống kê trên hai phương diện: tỉ lệ bối cảnh môi trường và độ chi tiết của các bản mô tả (captions).




Figure 5.1: Trục quan hóa phân bố các nhóm bối cảnh (trái) và Phân bố độ dài chú thích theo số lượng từ (phải)

Nhận xét từ Hình 5.1:

- **Về phân bố bối cảnh (Biểu đồ tròn):** Tập dữ liệu thể hiện sự ưu tiên rõ rệt cho các tình huống di chuyển ngoài trời. Hai nhóm *Đường phố* và *Phương tiện* mỗi nhóm chiếm tỉ trọng bằng nhau là 37.5% (tổng cộng 75%). Đây là những môi trường tiềm

ẩn nhiều nguy hiểm và vật cản thay đổi liên tục, đòi hỏi mô hình phải có độ chính xác cao. Nhóm bối cảnh *Trong nhà* chiếm 25%, tập trung vào việc nhận diện đồ đạc và định hướng không gian hẹp.

- **Về độ dài chú thích (Biểu đồ hộp):** Số lượng từ trong chú thích phản ánh mức độ phức tạp và lượng thông tin hướng dẫn mà mô hình cần đạt được:
 - **Nhóm Đường phố:** Có độ dài trung bình cao nhất (trung vị khoảng 39 từ) và dải phân bố rộng nhất. Các chú thích trong nhóm này thường rất chi tiết, có những mẫu đạt tới 60 từ. Điều này cho thấy bối cảnh đường phố chứa nhiều thực thể (vĩa hè, cột điện, người đi bộ) và cần nhiều từ ngữ chỉ hướng để mô tả chính xác vị trí vật cản.
 - **Nhóm Phương tiện:** Có độ dài ổn định với trung vị khoảng 36 từ. Mặc dù tập trung vào các đối tượng động như xe cộ, nhưng cấu trúc mô tả có phần đồng nhất hơn so với bối cảnh đường phố chung.
 - **Nhóm Trong nhà:** Có độ dài chú thích ngắn nhất (trung vị 35 từ). Tuy nhiên, so với các bộ dữ liệu Image Captioning phổ thông, mức 35 từ vẫn là một con số rất lớn, đảm bảo cung cấp đầy đủ thông tin về các vật dụng nội thất và lối đi cho người dùng.

Ý nghĩa đối với huấn luyện mô hình: Sự phân hóa về độ dài chú thích cho thấy tập dữ liệu không chỉ dừng lại ở việc gán nhãn đơn giản. Việc nhóm *Đường phố* có độ dài chú thích vượt trội là minh chứng cho việc dữ liệu đã được làm giàu bằng các thông tin cảnh báo và chỉ dẫn di chuyển thực tế. Độ dài trung bình trên 30 từ ở tất cả các nhóm đặt ra thách thức cho mô hình trong việc duy trì tính mạch lạc của câu (long-range dependency), nhưng đồng thời cung cấp giá trị sử dụng cao cho người khiếm thị trong việc hình dung không gian xung quanh.

5.2 Phân tích đặc trưng hình học (Geometry Analysis)

Sau bước tiền xử lý, nhóm thực hiện phân tích đặc trưng hình học trên toàn bộ tập dữ liệu. Bước này giúp kiểm soát chất lượng, nhằm xác nhận tính nhất quán của dữ liệu trước khi đưa vào huấn luyện mô hình.




Figure 5.2: Kết quả kiểm chứng kích thước ảnh và tỉ lệ khung hình sau chuẩn hóa

Phân tích Hình 5.2:

- **Biểu đồ tương quan Width vs Height (trái):** Toàn bộ 8.000 mẫu dữ liệu tập trung mật độ tuyệt đối tại tọa độ (224,224). Kết quả này xác nhận quy trình Resize đã được thực hiện chính xác và đồng bộ trên tất cả các thư mục thành phần (*street*, *transport*, *house*), không để lại các mẫu lỗi kích thước.
- **Biểu đồ phân bố tỉ lệ khung hình (phải):** Chỉ số Aspect Ratio đạt giá trị duy nhất là 1.0 (tỉ lệ hình vuông). Đường gạch đỏ thể hiện giá trị trung bình trùng khớp hoàn toàn với cấu trúc Tensor đầu vào mà các kiến trúc Vision Encoder như CLIP hay ViT yêu cầu.

Ý nghĩa đối với quá trình huấn luyện: Việc xác thực dữ liệu đạt chuẩn 224×224 mang lại các lợi ích kỹ thuật quan trọng cho đề án:

- **Tính ổn định của Batch Training:** Đảm bảo quá trình nạp dữ liệu theo lô (Batch) vào GPU diễn ra thông suốt, tránh các lỗi ngắt quãng do sai lệch kích thước ma trận giữa các mẫu ảnh khác nhau.

- **Tối ưu hóa tài nguyên:** Kích thước này giúp cân bằng giữa việc giữ lại chi tiết vật thể (như biển báo, số hiệu xe) và việc tiết kiệm bộ nhớ VRAM, cho phép tăng tốc độ huấn luyện trên các dòng mô hình như Qwen2-VL-2B hoặc BLIP.
- **Bảo toàn đặc trưng:** Do dữ liệu đã được đưa về tỉ lệ nhất quán, mô hình sẽ không gặp hiện tượng sai lệch hình dáng vật thể, giúp hệ thống nhận diện chính xác các chướng ngại vật hỗ trợ người khiếm thị.

5.3 Phân tích đặc trưng ngôn ngữ định hướng

5.3.1 Phân tích vốn từ vựng theo từng bối cảnh cụ thể (Word Cloud)

Để đánh giá sự phân hóa từ vựng và tính thực tế của các bản chú thích, nhóm thực hiện trực quan hóa mây từ vựng cho ba bối cảnh chính: *Đường phố*, *Phương tiện* và *Trong nhà*.



Figure 5.3: Mây từ vựng phân hóa theo 3 bối cảnh chính trong tập dữ liệu

Phân tích chi tiết từng bối cảnh:

- **Bối cảnh Đường phố:** Nhóm nhận thấy các thực thể chiếm ưu thế là hạ tầng giao thông như “vĩa hè”, “lề đường”, “người đi bộ”. Các từ chỉ hướng như “phía trước”, “bên phải” xuất hiện rất lớn, đi kèm các động từ mạnh như “hãy”, “cẩn thận”. Điều này cho thấy dữ liệu tập trung vào việc hướng dẫn người khiếm thị đi đúng làn đường an toàn và phòng tránh các vật cản tĩnh trên lộ trình.
- **Bối cảnh Phương tiện:** Mây từ vựng tập trung vào các đối tượng động và môi trường trung chuyển công cộng như “xe buýt”, “tàu hỏa”, “sân ga”, “chiếc xe”. Các từ như “đổi diện”, “trước mặt” và “đang chạy” xuất hiện dày đặc, phản ánh mục tiêu

giúp người dùng nhận diện khoảng cách với các phương tiện đang di chuyển nhằm tránh va chạm.

- **Bối cảnh Trong nhà:** Từ vựng thay đổi hoàn toàn sang các vật dụng sinh hoạt và không gian kín như “*bàn ăn*”, “*bồn rửa*”, “*tủ*”, “*giường ngủ*”. Thay vì cảnh báo tốc độ hay làn đường, chú thích ở đây tập trung vào độ gần (“*gần*”, “*cạnh*”) và cấu trúc không gian nội thất, giúp người dùng định vị các vật dụng phục vụ sinh hoạt cá nhân.

So sánh:

Nhóm đã rút ra những điểm khác biệt cốt lõi giữa ba tập từ vựng này:

- **Về quy mô thực thể:** Có sự chuyển dịch rõ rệt từ các thực thể quy mô lớn, hạ tầng (Đường phố) sang các đối tượng động, nguy hiểm (Phương tiện) và cuối cùng là các vật dụng nhỏ, tĩnh (Trong nhà).
- **Về tính chất cảnh báo:** Nhóm *Đường phố* và *Phương tiện* mang tính báo động cao với các từ như “*nguy hiểm*”, “*tuyệt đối*”, trong khi nhóm *Trong nhà* mang tính chất hỗ trợ định hướng không gian nhẹ nhàng hơn.
- **Sự khác biệt về hệ quy chiếu:** Ở môi trường ngoài trời, hệ quy chiếu thường dựa trên các mốc cố định (*vĩa hè*, *lề*), còn trong nhà hệ quy chiếu dựa trên các vật dụng nội thất (*cạnh bàn*, *trên giường*).

Ý nghĩa đối với đồ án:

Việc phân tích Word Cloud mang lại cho nhóm những insight quan trọng:

1. **Độ bao phủ ngữ nghĩa tốt:** Sự phân hóa từ vựng rõ rệt chứng minh tập dữ liệu không bị trùng lặp nội dung, đảm bảo mô hình có thể học được vốn từ phong phú cho nhiều tình huống thực tế khác nhau.
2. **Tính nhân văn và ứng dụng:** Việc các từ ngữ chỉ hướng (*trái*, *phải*, *trước*) và lời khuyên (*hãy*, *nên*, *chú ý*) luôn là trung tâm của cả 3 đám mây từ chứng tỏ dữ liệu đã bám sát mục tiêu hỗ trợ người khiếm thị, không chỉ dừng lại ở việc gán nhãn ảnh đơn thuần.
3. **Cơ sở cho việc huấn luyện:** Nhóm em tin rằng với sự đa dạng và chi tiết này, mô hình sẽ hình thành được khả năng phản xạ ngôn ngữ linh hoạt tùy theo bối cảnh môi trường mà người dùng đang đứng.

5.3.2 Phân tích cấu trúc cụm từ định hướng (Bigram Analysis)

Nếu mây từ vựng cho nhóm em cái nhìn tổng quan về các từ đơn lẻ, thì việc phân tích các cụm hai từ (Bigrams) xuất hiện thường xuyên nhất sẽ giúp nhận diện được logic câu lệnh và cách thức các thực thể được kết nối với các lời chỉ dẫn an toàn.




Figure 5.4: Top 20 cụm từ (Bigrams) xuất hiện thường xuyên nhất trong các bản chú thích

Phân tích các nhóm cụm từ chức năng:

Dựa trên kết quả thống kê tại Hình 5.4, nhóm em nhận thấy các cụm từ không xuất hiện ngẫu nhiên mà tập trung vào 4 nhóm chức năng cốt lõi phục vụ đối tượng người khiếm thị:

- **Nhóm xác định vị trí trọng tâm:** Cụm từ “*phía trước*” đứng đầu danh sách với tần suất áp đảo (hơn 17,500 lần), kết hợp cùng “*trước mặt*”, “*bên phải*”, “*bên trái*”. Nhóm em nhận định đây là các tổ hợp từ quan trọng nhất giúp người dùng định vị vật cản trong không gian theo hệ quy chiếu cá nhân một cách tức thời.
- **Nhóm ngôn ngữ hành động và tương tác:** Sự xuất hiện dày đặc của các cụm “*bạn hãy*”, “*bạn cần*”, “*di chuyển*” chứng minh rằng bộ dữ liệu của nhóm em mang tính chất **hỗ trợ hành động** (Action-oriented) thay vì chỉ mô tả tĩnh. Điều này giúp mô

hình sinh chú thích sau này đóng vai trò như một người dẫn đường thực thụ, đưa ra các yêu cầu cụ thể để người dùng thực hiện.

- **Nhóm cảnh báo mức độ an toàn:** Các cụm từ như “*an toàn*”, “*cẩn thận*”, “*chú ý*”, “*tuyệt đối*” (thường đi kèm thành “*tuyệt đối cẩn thận*”) cho thấy một hệ thống cảnh báo đa cấp độ. Ý nghĩa của việc này là mô hình sau khi huấn luyện sẽ có xu hướng ưu tiên sinh ra các cảnh báo trước khi mô tả các chi tiết phụ, giúp người dùng xử lý tình huống nguy hiểm kịp thời.
- **Nhóm phân định hạ tầng di chuyển:** Các cặp từ “*vĩa hè*”, “*lòng đường*”, “*lối đi*” phản ánh cấu trúc câu giúp người dùng phân biệt giữa khu vực an toàn và khu vực nguy hiểm có xe cộ. Đặc biệt, cụm từ “*dùng gậy*” là một phát hiện thú vị của nhóm em, minh chứng cho việc dữ liệu được biên soạn rất sát với hành vi sử dụng công cụ hỗ trợ thực tế của người khiếm thị.

Sự khác biệt và Insight rút ra từ phân tích:

Qua việc quan sát các cụm từ này, nhóm em đã rút ra những nhận định quan trọng cho quá trình xây dựng mô hình:

- **Tính nhất quán về cấu trúc:** Các bản chú thích tuân theo một khuôn mẫu logic rõ ràng: [Vị trí] + [Thực thể] + [Cảnh báo/Chỉ dẫn]. Ví dụ: “*Phía trước có xe buýt, bạn hãy cẩn thận*”.
- **Khác biệt so với dữ liệu thông thường:** So với các tập dữ liệu Image Captioning phổ biến (thường mô tả khách quan như “*A person sitting*”), tập dữ liệu của nhóm em mang tính **hướng mục tiêu (Goal-oriented)**, tập trung vào sự an toàn và khả năng di chuyển của con người.

Kết luận về đặc trưng ngôn ngữ:

Thông qua việc phân tích Word Cloud và Bigrams, nhóm em tự tin khẳng định tập dữ liệu 8,000 ảnh này đã đạt được độ chín về mặt nội dung ngôn ngữ. Sự kết hợp giữa danh từ thực thể và các cụm từ chỉ dẫn tạo nên một nền tảng dữ liệu vững chắc, sẵn sàng cho giai đoạn huấn luyện để mô hình có thể cung cấp những thông báo thực sự có giá trị cho người khiếm thị trong thực tế.

5.3.3 Sự liên kết giữa cấu trúc cụm từ và đặc trưng bối cảnh

Để có cái nhìn sâu sắc hơn về cách bộ dữ liệu vận hành, nhóm em không lựa chọn từ khóa phân tích một cách ngẫu nhiên. Thay vào đó, nhóm em dựa trên kết quả từ biểu đồ Top 20 Bigrams (Hình 5.4) để trích xuất ra các đơn vị từ vựng nòng cốt.

Lý do lựa chọn từ khóa cho heat map: Từ danh sách các cụm từ phổ biến nhất như “*phía trước*”, “*vĩa hè*”, “*dùng gậy*”, “*trước mặt*”, nhóm em đã tách chúng thành các từ đơn đóng vai trò là các “điểm neo” thông tin. Việc phân tích sự phân bố của các điểm neo này qua từng bối cảnh cụ thể (Đường phố, Phương tiện, Trong nhà) sẽ giúp nhóm em xác định được quy luật chỉ dẫn mà mô hình cần học.



Figure 5.5: Ma trận tỷ lệ % xuất hiện của các từ khóa nòng cốt (được trích xuất từ Bigrams) theo bối cảnh

Phân tích ý nghĩa của heat map:

Dựa trên Hình 5.5, nhóm em nhận thấy sự chuyển dịch rõ rệt của các thành phần chỉ dẫn khi môi trường thay đổi:

- **Bối cảnh Đường phố:** Đây là bối cảnh có sự xuất hiện cân bằng nhất của các thành

phần hạ tầng giao thông. Từ khóa “đường” (67%) và “xe” (58%) chiếm ưu thế, kết hợp với các từ chỉ biên giới di chuyển như “mép” (28%) và “vĩa hè” (34%). Điều này khẳng định trong bối cảnh này, bộ từ vựng tập trung vào việc định vị người dùng trong một không gian mở và rộng lớn.

- **Bối cảnh Phương tiện:** Nhóm em nhận thấy một chỉ số đặc biệt: từ “trước” đạt tỷ lệ cao nhất (82%). Khi kết hợp với từ “mặt” (46%), nó tạo thành cấu trúc cảnh báo va chạm trực diện thường thấy trong Bigram là “trước mặt”. Điều này hoàn toàn hợp lý vì trong môi trường có phương tiện đang di chuyển, việc cảnh báo vật cản ngay trước mặt là ưu tiên sống còn. Ngoài ra, sự xuất hiện của từ “tàu” (38%) là dấu hiệu nhận biết bối cảnh đặc trưng của nhóm này.
- **Bối cảnh Trong nhà:** Có sự chuyển dịch sang hệ quy chiếu 360 độ. Các từ “phía” (77%) và “bên” (65%) chiếm tỷ lệ cao vượt trội so với các nhóm khác. Nhóm em lý giải rằng trong không gian kín, vật cản (đồ nội thất) xuất hiện ở mọi hướng, đòi hỏi chú thích phải sử dụng đa dạng các từ chỉ hướng để giúp người khiếm thị hình dung không gian. Đáng chú ý, các thực thể ngoài trời như “vĩa hè” và “tàu” có tỷ lệ bằng 0, chứng minh dữ liệu có độ sạch và tính phân hóa cực kỳ cao.

Ý nghĩa tổng quát của phân tích:

Từ sự liên kết giữa cấu trúc câu (Bigrams) và sự phân bố theo bối cảnh (Heatmap), nhóm em rút ra được ý nghĩa cốt lõi của bộ dữ liệu:

1. **Tính thích nghi của ngôn ngữ:** Bộ từ vựng không đứng yên mà tự động điều chỉnh độ tập trung tùy theo mức độ nguy hiểm của môi trường (tập trung vào phía trước khi có phương tiện, tập trung vào các bên khi ở trong nhà).
2. **Mục tiêu dẫn đường nhất quán:** Từ khóa “bạn” luôn xuất hiện ổn định ở mức cao (58-76%) trên mọi bối cảnh, cho thấy tập dữ liệu luôn giữ vững cấu trúc hội thoại hỗ trợ trực tiếp.
3. **Độ tin cậy cho mô hình:** Sự phân hóa rạch ròi của các thực thể đặc trưng sẽ giúp mô hình tránh được hiện tượng sinh từ sai ngữ cảnh, đảm bảo thông tin cung cấp cho người khiếm thị luôn chính xác và an toàn.

5.4 Phân tích đặc trưng thị giác (Visual Analysis)

Sự khác biệt về điều kiện chiếu sáng và độ phức tạp hình ảnh ảnh hưởng trực tiếp đến khả năng trích xuất đặc trưng của Vision Encoder. Nhóm tiến hành phân tích độ sáng (Brightness) và mật độ cạnh (Edge Density) nhằm hiểu rõ đặc điểm dữ liệu và những thách thức tiềm ẩn đối với mô hình.




Figure 5.6: Phân tích đặc trưng quang học và cấu trúc ảnh theo từng chủ đề

Phân tích Hình 5.6:

- **Độ sáng trung bình (Hình a):** Nhóm *Trong nhà* có độ sáng cao nhất (đỉnh khoảng 160), cho thấy điều kiện ánh sáng ổn định. Trong khi đó, *Phương tiện* và *Đường phố* có độ sáng thấp hơn (khoảng 110–120), phản ánh đặc trưng ánh sáng ngoài trời và các bề mặt hấp thụ sáng như nhựa đường hoặc vỏ xe.
- **Độ phức tạp chi tiết (Hình b):** Nhóm *Phương tiện* có mật độ cạnh cao nhất (khoảng 0.16), do chứa nhiều chi tiết như khung xe, bánh xe và bề mặt phản chiếu. Ngược lại, *Trong nhà* có mật độ cạnh thấp nhất (khoảng 0.11), phù hợp với các bề mặt phẳng như tường và sàn. Nhóm *Đường phố* ở mức trung bình (khoảng 0.12) với các chi tiết từ kiến trúc và biển hiệu.

Nhận xét:


- **Thách thức trích xuất đặc trưng:** Mật độ cạnh cao ở nhóm *Phương tiện* khiến mô hình khó tách đối tượng chính khỏi nền, đòi hỏi cơ chế Attention hoạt động hiệu quả để giảm nhiễu.
- **Biến động ánh sáng:** Nhóm *Đường phố* và *Phương tiện* có dải độ sáng rộng, cho thấy dữ liệu bao quát nhiều điều kiện thực tế, giúp mô hình ổn định hơn khi triển khai.

- **Nhận diện ngữ cảnh:** Sự khác biệt rõ ràng về độ sáng và độ phức tạp giữa các nhóm là tín hiệu hữu ích để mô hình học đặc trưng thị giác, từ đó hỗ trợ phân biệt bối cảnh và sinh mô tả chính xác hơn.

5.5 Trực quan hóa mẫu dữ liệu (Qualitative Preview)

Việc quan sát ngẫu nhiên các mẫu dữ liệu thực tế giúp đánh giá sự tương quan giữa hình ảnh và các câu chú thích (annotations). Đây là bước kiểm chứng cuối cùng để đảm bảo ngôn ngữ sinh ra bám sát mục tiêu hỗ trợ người khiếm thị di chuyển an toàn.

Nhóm: Phương tiện
Caption: có nhiều xe ô tô đang đỗ chờ đèn tín hiệu trên lòng đường phía trước, bạn hãy tiếp tục đứng chờ trên lề đường dành cho người đi bộ, rà gây cẩn thận và đợi luồng xe đi qua



(a) Mẫu dữ liệu chủ đề Phương tiện/Giao thông

Nhóm: Đường phố
Caption: lối đi trên vỉa hè khu vực góc ngã tư tương đối rộng nhưng vướng cột đèn và các trụ sắt đỡ biển báo giao thông, bạn hãy dùng gậy quét ngang để lách qua không đập ngực



(b) Mẫu dữ liệu chủ đề Đường phố

Nhóm: Trong nhà
Caption: có bồn rửa mặt ở phía gần bên trái cùng vách kính tắm ở phía xa bên phải, hãy chú ý giữ khoảng cách khi đi vào giữa nhằm không đâm sầm vào vách kính



(c) Mẫu dữ liệu chủ đề Trong nhà

Figure 5.7: Trực quan hóa các mẫu hình ảnh và chú thích thực tế trong tập dữ liệu

Phân tích đặc điểm nội dung nhãn (Hình 5.7): Dựa trên các mẫu quan sát được, cấu trúc chú thích của nhóm đã đạt được sự đồng nhất cao về phong cách diễn đạt:

- **Cấu trúc "Mô tả + Chỉ dẫn":** Mỗi mẫu đều bao gồm hai phần rõ rệt. Phần đầu nhận diện các vật thể và trạng thái (xe đang đỗ, vỉa hè vướng cột đèn, bồn rửa mặt). Phần sau đưa ra lời khuyên hành động cụ thể (rà gây cẩn thận, quét gây ngang để tránh đập ngực, giữ khoảng cách với vách kính).
- **Tính nhạy bén với vật cản:** Các chú thích thể hiện khả năng nhận diện các chi tiết nguy hiểm đặc thù đối với người khiếm thị như "chướng ngại vật tầm cao" (trụ sắt đỡ biển báo) hay "vật thể trong suốt" (vách kính tắm) – những thứ vốn rất khó nhận diện bằng gậy dò đường thông thường.
- **Định hướng không gian rõ ràng:** Việc sử dụng các trạng từ chỉ vị trí (phía gần bên trái, phía xa bên phải, trên lề đường) giúp người dùng hình dung được cấu trúc không gian xung quanh một cách mạch lạc.

Kết luận: Qua các phân tích định lượng và định tính (Hình 5.7), tập dữ liệu 8.000 ảnh nhóm nhận xét là đạt độ tin cậy cao, bối cảnh phân hóa rõ rệt và ngôn ngữ mang tính chỉ dẫn rõ ràng. Tóm lại, dữ liệu sau khi tiền xử lý cho thấy sự ổn định, đủ tin cậy, đã sẵn sàng tiến vào giai đoạn huấn luyện mô hình.

Lời cảm ơn

Đầu tiên, nhóm chúng em xin bày tỏ lòng biết ơn sâu sắc đến TS. Bùi Tiến Lên, người đã trực tiếp giảng dạy và tận tình hướng dẫn nhóm trong suốt quá trình thực hiện môn học Nhập môn học máy.

Đề tài "Xây dựng hệ thống Image Captioning tiếng Việt hỗ trợ người khiếm thị" là một bài toán đòi hỏi sự đầu tư lớn về mặt dữ liệu và kỹ thuật. Nhóm chúng em xin đặc biệt gửi lời cảm ơn chân thành đến Thầy vì đã dành thời gian nhiệt tình giải đáp các thắc mắc, đặc biệt là trong giai đoạn quan trọng nhất: xây dựng bộ dữ liệu huấn luyện.

Nhờ những chỉ dẫn của Thầy về việc xác định số lượng mẫu phù hợp cũng như cách phân bổ dữ liệu hợp lý cho từng chủ đề (giao thông đường phố, phương tiện công cộng và không gian trong nhà), nhóm đã định hướng được quy trình thực nghiệm khoa học, đảm bảo tính khách quan và hiệu quả cho mô hình.

Mặc dù đã nỗ lực hoàn thành đề án với tinh thần nghiêm túc nhất, song do kiến thức và kinh nghiệm thực tế còn hạn chế, dự án chắc chắn vẫn còn những điểm thiếu sót. Nhóm rất mong nhận được những nhận xét và góp ý thẳng thắn từ Thầy để chúng em có thể hoàn thiện hơn các công trình nghiên cứu trong tương lai.

Một lần nữa, chúng em xin chân thành cảm ơn Thầy.

Tài liệu tham khảo

- [1] P. Wang et al., "Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution," *arXiv preprint arXiv:2409.12191*, 2024. [Online]. Available: <https://arxiv.org/abs/2409.12191>
- [2] K. T. Doan et al., "Vintern-1B: An Efficient Multimodal Large Language Model for Vietnamese," *arXiv preprint arXiv:2408.12480*, 2024. [Online]. Available: <https://arxiv.org/abs/2408.12480>
- [3] J. Li, D. Li, C. Xiong, and S. Hoi, "BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation," *arXiv preprint arXiv:2201.12086*, 2022. [Online]. Available: <https://arxiv.org/abs/2201.12086>
- [4] J. Wang et al., "GIT: A Generative Image-to-text Transformer for Vision and Language," *arXiv preprint arXiv:2205.14100*, 2022. [Online]. Available: <https://arxiv.org/abs/2205.14100>
- [5] Perceval-Wilhelm, "Image-captioning-convert-to-Vietnamese," *GitHub repository*, 2023. [Online]. Available: <https://github.com/Perceval-Wilhelm/Image-captioning-convert-to-Vietnamese>
- [6] T.-Y. Lin et al., "Microsoft COCO: Common Objects in Context," in *Proc. European Conf. Comput. Vis. (ECCV)*, 2014, pp. 740–755. [Online]. Available: <https://cocodataset.org>