

VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY

UNIVERSITY OF SCIENCE

FACULTY OF INFORMATION TECHNOLOGY

Final Project

Topic: Xây dựng hệ thống Image Captioning tiếng Việt hỗ trợ người khiếm thị trong đời sống hàng ngày

Course: Nhập môn học máy(23KHDL1)

Group Members:

Phạm Khánh Linh (23127083)

Võ Trung Hiếu (23127190)

Nguyễn Thành Lợi (23127408)

Lê Quốc Thiện (23127481)

Phạm Quang Thịnh (23127485)

Instructing Lecturers:

Dr. Bùi Tiến Lên

M.Sc. Lê Nhựt Nam

Võ Nhật Tân

April 18, 2026



Contents

THÔNG TIN NHÓM VÀ PHÂN CÔNG CÔNG VIỆC	1
1 Giới thiệu	2
1.1 Phân tích Vấn đề (Problem Definition)	2
1.2 Mục tiêu của Đồ án	2
1.3 Tổng quan về Phương pháp	2
2 Thu thập và Phân tích Dữ liệu	4
2.1 Nguồn và Phương pháp Thu thập	4
2.2 Tiền xử lý và Làm sạch	5
2.3 Phân tích Khám phá Dữ liệu (EDA)	6
2.3.1 Phân bố bối cảnh và Đặc trưng độ dài chú thích	6
2.3.2 Phân tích vốn từ vựng và Cụm từ định hướng	7
2.3.3 Sự liên kết giữa từ khóa và đặc trưng bối cảnh	8
2.3.4 Phân tích đặc trưng thị giác (Visual Analysis)	9
2.3.5 Trực quan hóa mẫu dữ liệu thực tế	9
3 Lựa chọn và Huấn luyện Mô hình	10
3.1 Chuẩn bị Dữ liệu cho Mô hình	10
3.2 Lựa chọn và Kiến trúc Mô hình	10
3.2.1 So sánh các mô hình thử nghiệm	10
3.2.2 Kiến trúc chi tiết các mô hình thử nghiệm	13
3.3 Cấu hình Huấn luyện	15
3.3.1 Hàm mất mát và Thuật toán tối ưu	15
3.3.2 Bảng tổng hợp siêu tham số (Hyperparameters)	16
3.3.3 Phương pháp tinh chỉnh tham số	16
4 Kết quả và Thảo luận	17
4.1 Kết quả Thử nghiệm	17
4.1.1 Biểu đồ quá trình học (Learning Curves)	17
4.1.2 Đánh giá hiệu năng trên tập Validation	17
4.1.3 Kết quả tổng thể trên tập Test	18

4.2	Thảo luận và Phân tích lỗi	18
4.2.1	Hiện tượng Overfitting và Underfitting	18
4.2.2	Phân tích các trường hợp sai và hạn chế	19
5	Xây dựng và Triển khai Ứng dụng	21
5.1	Kiến trúc tổng thể của hệ thống	21
5.2	Luồng hoạt động của ứng dụng	22
5.3	Triển khai backend	22
5.4	Triển khai frontend	23
5.5	Kết quả triển khai thực tế	25
6	Kết luận	26

THÔNG TIN NHÓM VÀ PHÂN CÔNG CÔNG VIỆC

Dưới đây là danh sách các thành viên trong nhóm cùng vai trò và đóng góp cụ thể của từng cá nhân trong suốt quá trình thực hiện đồ án:

Họ và tên	MSSV	Phân công công việc	Mức độ
Phạm Khánh Linh	23127083	Xây dựng dataset, so sánh và đánh giá zero-shot models, quản lý UX & Accessibility, deploy ứng dụng.	100%
Võ Trung Hiếu	23127190	Xây dựng dataset, lựa chọn models phù hợp với bài toán, backend developer, kiểm soát chất lượng ứng dụng.	100%
Nguyễn Thành Lợi	23127408	Xây dựng dataset, so sánh và đánh giá zero-shot model, frontend developer, kiểm soát chất lượng ứng dụng.	100%
Lê Quốc Thiện	23127481	Xây dựng dataset, tiền xử lý + EDA, kiểm soát chất lượng ứng dụng, quản lý nội dung báo cáo và trình bày.	100%
Phạm Quang Thịnh	23127485	Xây dựng dataset, so sánh và đánh giá zero-shot model, fine-tune và đánh giá model được chọn, kiểm thử ứng dụng (tester).	100%

Bảng 1: Bảng phân công công việc và mức độ hoàn thành của các thành viên.

1 Giới thiệu

1.1 Phân tích Vấn đề (Problem Definition)

Trong đời sống hằng ngày, thông tin thị giác đóng vai trò then chốt giúp con người nhận biết môi trường, định vị vật thể và tương tác an toàn. Tuy nhiên, đối với người khiếm thị, việc thiếu hụt khả năng quan sát tạo ra những rào cản rất lớn trong việc di chuyển độc lập. Đặc biệt, tại Việt Nam, hạ tầng giao thông phức tạp với sự đan xen của nhiều loại phương tiện, vật cản không cố định trên vỉa hè đòi hỏi một giải pháp hỗ trợ thông minh, có khả năng hiểu ngữ cảnh địa phương.

Bài toán trọng tâm của đề án là xây dựng hệ thống **Image Captioning** (Chú thích hình ảnh) bằng tiếng Việt. Hệ thống này không chỉ dừng lại ở việc liệt kê các vật thể có trong ảnh mà còn phải đóng vai trò như một trợ lý ảo, cung cấp các câu mô tả có ý nghĩa kèm theo hướng dẫn di chuyển an toàn. Việc giải quyết bài toán này trong bối cảnh thực tiễn Việt Nam mang ý nghĩa nhân văn sâu sắc, giúp người khiếm thị tự tin hơn và giảm thiểu rủi ro tai nạn trong sinh hoạt hằng ngày.

1.2 Mục tiêu của Đề án

Dựa trên yêu cầu hỗ trợ người dùng khiếm thị, nhóm xác lập các mục tiêu cụ thể sau:

- **Sinh mô tả tự nhiên:** Tạo ra một câu mô tả hoàn chỉnh, đúng ngữ pháp tiếng Việt, tóm tắt chính xác các thực thể, hành động và mối quan hệ giữa chúng trong hình ảnh.
- **Hướng dẫn định hướng:** Tích hợp các lời khuyên di chuyển và cảnh báo nguy hiểm trực tiếp vào câu chú thích (ví dụ: mô tả vật cản phía trước và gợi ý hướng tránh).
- **Xây dựng bộ dữ liệu chất lượng:** Tổng hợp và gán nhãn thành công 8.000 cặp ảnh-chú thích đa dạng bối cảnh từ đường phố, phương tiện công cộng đến không gian trong nhà.
- **Tối ưu hóa công nghệ:** Lựa chọn và fine-tune mô hình đa phương thức (Vision-Language Model) hiện đại để đạt được sự cân bằng giữa độ chính xác ngôn ngữ và tốc độ xử lý thực tế.
- **Mở rộng ứng dụng:** Hướng tới tích hợp module chuyển đổi văn bản thành giọng nói (Text-to-Speech) để người dùng có thể tiếp nhận thông tin một cách thuận tiện nhất.

1.3 Tổng quan về Phương pháp

Để hiện thực hóa các mục tiêu trên, nhóm thực hiện quy trình tiếp cận tổng thể từ thu thập dữ liệu đến triển khai sản phẩm như sau:

1. **Xây dựng dữ liệu:** Thu thập hình ảnh từ các nguồn Kaggle và COCO. Sử dụng quy trình gắn nhãn tự động bằng NotebookLM kết hợp với Gemini để tạo ra 5 bản chú thích đa dạng cho mỗi hình ảnh theo cấu trúc "Mô tả + Chỉ dẫn". Sau đó, thực hiện kiểm duyệt thủ công để đảm bảo tính chính xác.
2. **Phân tích và Tiền xử lý:** Thực hiện phân tích EDA về phân bố bối cảnh, độ dài caption và đặc trưng hình học của ảnh. Tiền xử lý ảnh về kích thước chuẩn và chuẩn hóa định dạng văn bản để sẵn sàng cho huấn luyện.
3. **Thử nghiệm mô hình:** So sánh hiệu năng giữa 3 kiến trúc mô hình mạnh mẽ: BLIP2-Flan-T5, Vintern-1B và Qwen2-VL-2B. Đánh giá dựa trên các chỉ số ngôn ngữ (BLEU, CIDEr, ROUGE-L) và chi phí tài nguyên tính toán.
4. **Huấn luyện chuyên sâu:** Sử dụng kỹ thuật PEFT-LoRA để fine-tune mô hình được lựa chọn trên tập dữ liệu đã xây dựng, giúp mô hình thích nghi tốt với cấu trúc câu lệnh hỗ trợ người khiếm thị.
5. **Triển khai sản phẩm:** Đóng gói mô hình thành ứng dụng web/app tích hợp API, đảm bảo khả năng phản hồi nhanh chóng và giao diện thân thiện với người dùng.

2 Thu thập và Phân tích Dữ liệu

2.1 Nguồn và Phương pháp Thu thập

Dữ liệu của đồ án được xây dựng tập trung vào mục tiêu hỗ trợ người khiếm thị định hướng và di chuyển an toàn. Nhóm đã thực hiện tổng hợp 8.000 cặp ảnh-chú thích thông qua việc kết hợp các nguồn dữ liệu mở và quy trình gán nhãn chuyên biệt bằng trí tuệ nhân tạo.

- **Nguồn dữ liệu hình ảnh:** Hình ảnh được trích xuất và sàng lọc từ các bộ dữ liệu uy tín nhằm bao quát các tình huống sinh hoạt thực tế:
 - **Kaggle:** Ảnh giao thông đường phố Việt Nam và ảnh bối cảnh trong nhà
 - * *za_traffic_2020*
 - * *House Rooms & Streets Dataset*
 - **COCO:** Ảnh các vật thể theo bối cảnh
 - * *Ảnh phương tiện giao thông*
- **Quy trình thu thập và gán nhãn (4 bước):** Để đảm bảo dữ liệu mang tính định hướng hành động (Action-oriented), nhóm thực hiện quy trình xây dựng dataset như sau:
 1. **Xác định chủ đề và tiêu chí lọc:** Nhóm thống nhất phân chia dữ liệu thành 3 nhóm chủ đề chính bao gồm: Đường phố & Giao thông, Phương tiện công cộng, và Trong nhà. Các hình ảnh được lựa chọn phải đảm bảo tiêu chí về độ rõ nét và mô phỏng được góc nhìn của người đi bộ.
 2. **Thu thập và Phân loại:** Sau khi tải về, các hình ảnh được phân loại thủ công vào đúng thư mục chủ đề. Nhóm tiến hành loại bỏ các ảnh trùng lặp, ảnh bị lỗi hiển thị hoặc các ảnh không phù hợp với mục tiêu hỗ trợ người khiếm thị.
 3. **Gán nhãn bằng AI (NotebookLM):** Đây là giai đoạn quan trọng nhất để tạo ra dữ liệu ngôn ngữ chất lượng cao. Nhóm sử dụng công cụ **Google NotebookLM** với 3 hệ thống câu lệnh (prompt) khác nhau cho mỗi chủ đề. Mỗi prompt hướng dẫn AI mô tả hình ảnh dưới góc nhìn trợ giúp người dùng (nhận diện vật cản, mô tả khoảng cách tương đối và đưa ra lời khuyên di chuyển). Kết quả mỗi hình ảnh được gán 5 câu chú thích độc lập, đa dạng về cách diễn đạt.
 4. **Kiểm tra và Xử lý ngoại lệ:** Đối với các trường hợp hình ảnh có xuất hiện khuôn mặt người (NotebookLM từ chối xử lý do chính sách bảo mật), nhóm chuyển sang sử dụng **Google Gemini** để hoàn tất việc gán nhãn. Cuối cùng, các thành viên thực hiện rà soát thủ công để đối chiếu tính chính xác giữa nội dung hình ảnh và câu lệnh hỗ trợ.

2.2 Tiền xử lý và Làm sạch

Sau khi thu thập, dữ liệu thô được đưa qua quy trình tiền xử lý nghiêm ngặt nhằm đảm bảo tính nhất quán và tối ưu hóa hiệu suất huấn luyện cho các mô hình đa phương thức. Quy trình này tập trung vào hai loại dữ liệu chính: hình ảnh (JPG) và chú thích văn bản (JSON).

- **Tiền xử lý dữ liệu hình ảnh:** Nhóm thực hiện chuẩn hóa hình ảnh để đáp ứng yêu cầu đầu vào của các kiến trúc Vision Encoder:
 - **Loại bỏ nhiễu và lọc chất lượng:** Tiến hành loại bỏ các hình ảnh bị lỗi hiển thị, ảnh không đúng chủ đề hoặc ảnh có điều kiện ánh sáng không phù hợp. Cụ thể, nhóm lọc bỏ các ảnh quá tối (độ sáng trung bình dưới 30) hoặc quá sáng (trên 230) để đảm bảo mô hình nhận diện được các chi tiết vật cản.
 - **Xử lý trùng lặp:** Thực hiện kiểm tra thủ công để phát hiện và loại bỏ các hình ảnh có nội dung trùng lặp quá nhiều dù khác tên tệp tin, tránh hiện tượng mô hình học thuộc lòng (overfitting) trên các dữ liệu lặp lại.
 - **Chuẩn hóa kích thước và định dạng:** Toàn bộ hình ảnh được đồng nhất định dạng .jpg và áp dụng resize ảnh sao cho cạnh dài ≤ 1024 và cạnh ngắn ≥ 224 , giúp tối ưu và cân bằng giữa việc giữ lại chi tiết vật thể (biển báo, chướng ngại vật nhỏ) và tiết kiệm tài nguyên bộ nhớ VRAM.
 - **Kiểm soát dung lượng:** Đảm bảo mỗi tệp ảnh sau tiền xử lý có dung lượng dưới 1.5 MB để tối ưu hóa tốc độ nạp dữ liệu (data loading) trong quá trình huấn luyện.
- **Tiền xử lý dữ liệu chú thích (JSON):** Dữ liệu văn bản được xử lý để tăng tính nhất quán và giảm độ phức tạp cho quá trình học ngôn ngữ:
 - **Chuẩn hóa nội dung (Normalization):** Chuyển đổi toàn bộ ký tự trong câu chú thích sang dạng viết thường và loại bỏ dấu chấm cuối câu. Nhóm cũng thực hiện rà soát để đảm bảo các câu chú thích đều chứa ký tự tiếng Việt có dấu đúng quy chuẩn.
 - **Lọc nhiễu văn bản:** Loại bỏ các bản chú thích không đáp ứng đủ ba tiêu chí cốt lõi: mô tả ngữ cảnh, xác định vị trí thực thể và đưa ra lời khuyên an toàn. Các câu chú thích quá lan man hoặc chứa thông tin không liên quan đến an toàn di chuyển đều bị loại bỏ hoặc gán nhãn lại.
 - **Xử lý dữ liệu thiếu (Missing values):** Đối với những hình ảnh có số lượng chú thích ít hơn 5, nhóm thực hiện bổ sung nhãn thông qua công cụ AI (Gemini/NotebookLM) và kiểm định lại thủ công để đảm bảo mọi mẫu dữ liệu đều đạt đủ số lượng 5 captions theo quy định.

- **Đảm bảo tính nhất quán:** Xác thực sự tồn tại và tính hợp lệ của đường dẫn file ảnh tương ứng với các trường thông tin trong tệp nhãn JSON, đảm bảo không có lỗi ánh xạ (mapping) khi đưa vào mô hình.


2.3 Phân tích Khám phá Dữ liệu (EDA)

Quá trình khám phá dữ liệu (Exploratory Data Analysis) đóng vai trò quan trọng trong việc thấu hiểu các đặc trưng cốt lõi của 8.000 cặp ảnh-chú thích, từ đó xây dựng chiến lược huấn luyện mô hình sinh chú thích hỗ trợ người khiếm thị một cách hiệu quả nhất.

2.3.1 Phân bố bối cảnh và Đặc trưng độ dài chú thích

Tập dữ liệu thể hiện sự ưu tiên rõ rệt cho các tình huống di chuyển ngoài trời, nơi tiềm ẩn nhiều nguy hiểm cho người khiếm thị. Theo thống kê, hai nhóm **Đường phố** và **Phương tiện** chiếm tỉ trọng bằng nhau là 37,5% (tổng cộng 75%), trong khi nhóm **Trong nhà** chiếm 25%.

Về độ dài chú thích, số lượng từ trong mỗi chú thích phản ánh mức độ phức tạp của từng bối cảnh. Nhóm Đường phố có độ dài chú thích trung bình cao nhất (trung vị khoảng 39 từ), cung cấp thông tin chi tiết về hạ tầng giao thông.



Hình 1: Trực quan hóa phân bố các nhóm bối cảnh và Phân bố độ dài chú thích theo số lượng từ

2.3.3 Sự liên kết giữa từ khóa và đặc trưng bối cảnh


Thông qua ma trận nhiệt (Heatmap), nhóm nhận thấy sự chuyển dịch rõ rệt của các thành phần chỉ dẫn khi môi trường thay đổi. Ví dụ, từ khóa "vía hè", "mép" xuất hiện nhiều ở bối cảnh Đường phố, trong khi "trước mặt" đạt tỉ lệ cao nhất (82%) ở bối cảnh Phương tiện nhằm cảnh báo va chạm trực diện.




Hình 4: Ma trận tỷ lệ % xuất hiện của các từ khóa nòng cốt theo bối cảnh

2.3.4 Phân tích đặc trưng thị giác (Visual Analysis)

Nhóm thực hiện phân tích độ sáng (Brightness) và mật độ cạnh (Edge Density) để hiểu rõ thách thức đối với Vision Encoder. Nhóm Phương tiện có mật độ cạnh cao nhất (0.16) do chi tiết phức tạp của xe cộ, trong khi nhóm Trong nhà có độ sáng ổn định và mật độ cạnh thấp nhất (0.11).



(a) Phân bố độ sáng trung bình



(b) Độ phức tạp (Edge Density)

Hình 5: Phân tích đặc trưng quang học và cấu trúc ảnh theo từng chủ đề

2.3.5 Trực quan hóa mẫu dữ liệu thực tế

Việc quan sát ngẫu nhiên các mẫu dữ liệu thực tế cho thấy cấu trúc chú thích đạt được sự đồng nhất cao theo khuôn mẫu: **[Vị trí] + [Thực thể] + [Cảnh báo/Chỉ dẫn]**. Điều này đảm bảo tính mạch lạc và dễ tiếp nhận cho người khiếm thị.

Nhóm: Trong nhà
 Caption: có bốn rửa mặt ở phía gần bên trái cùng vách kính tắm ở phía xa bên phải, hãy chú ý giữ khoảng cách khi đi vào giữa nhằm không đâm sầm vào vách kính



Hình 6: Trực quan hóa mẫu hình ảnh và chú thích thực tế trong tập dữ liệu

Kết luận, dựa trên các phân tích EDA định lượng và định tính, nhóm tự tin rằng tập dữ liệu đã đạt được độ chín về nội dung ngôn ngữ và sự ổn định về kỹ thuật hình ảnh, sẵn sàng cho giai đoạn huấn luyện mô hình chuyên sâu.

3 Lựa chọn và Huấn luyện Mô hình

3.1 Chuẩn bị Dữ liệu cho Mô hình

Trước khi đưa vào huấn luyện, nhóm thực hiện phân chia và xử lý dữ liệu để đảm bảo tính khách quan và hiệu quả học tập:

- **Tỷ lệ phân chia:** Bộ dữ liệu 8.000 mẫu được chia theo tỉ lệ **80:10:10**, tương ứng với 6.400 mẫu cho tập Huấn luyện (Train), 800 mẫu cho tập Kiểm định (Validation) và 800 mẫu cho tập Kiểm tra (Test).
- **Phương pháp phân chia:** Sử dụng kỹ thuật *Stratified Split* để đảm bảo sự cân bằng về tỉ lệ các nhóm bối cảnh (đường phố, phương tiện, trong nhà) trong cả ba tập dữ liệu.
- **Tiền xử lý cuối cùng:** Ảnh được resize về cạnh dài không quá 1024 px và cạnh ngắn tối thiểu 224 px để tận dụng cơ chế *Dynamic Resolution* của các mô hình hiện đại, giúp giữ lại các chi tiết nhỏ như biển báo hoặc vật cản ở xa.

3.2 Lựa chọn và Kiến trúc Mô hình

Để tìm ra giải pháp tối ưu cho bài toán sinh chú thích hình ảnh tiếng Việt hỗ trợ người khiếm thị, nhóm đã tiến hành khảo sát và thử nghiệm ba kiến trúc mô hình đa phương thức (Vision-Language Models) tiêu biểu. Mỗi mô hình đại diện cho một hướng tiếp cận công nghệ khác nhau.

3.2.1 So sánh các mô hình thử nghiệm

Ban đầu, nhóm không fine-tune ngay mà trước hết thực hiện suy diễn (inference) Zero-shot với cả ba mô hình trên cùng tập test gồm 800 ảnh. Việc này giúp đánh giá khách quan chất lượng mô tả ảnh, chi phí tính toán và mức sử dụng tài nguyên. Dựa trên kết quả so sánh, nhóm sẽ chọn ra mô hình tốt nhất để tiến hành fine-tune ở giai đoạn tiếp theo.

Quá trình suy diễn được thực hiện trong cùng một môi trường thực nghiệm (Google Colab, GPU T4) với cùng một câu lệnh (prompt) để đảm bảo tính công bằng:

"Viết đúng một câu ngắn (tối đa 60 từ) bằng tiếng Việt, mô tả vật thể hoặc chương ngại chính trong ảnh và đưa ra hướng dẫn di chuyển an toàn cho người mù, không giải thích thêm."

Riêng với phiên bản BLIP2-Flan-T5-XL (hoạt động tốt hơn với chỉ dẫn tiếng Anh), nhóm thiết kế prompt là phiên bản dịch sang tiếng Anh của câu lệnh trên. Sau khi mô hình sinh caption tiếng Anh,

nhóm sử dụng thư viện `googletrans` để dịch sang tiếng Việt. Kết quả này được lưu lại để phục vụ cho các bước đánh giá.

Kết quả thử nghiệm được đánh giá toàn diện trên ba nhóm tiêu chí:

- **Độ dài caption sinh ra (Length Metrics):** Đánh giá mức độ phù hợp về độ dài của câu chú thích so với tham chiếu:
 - **Tổng tokens:** Tổng số token của toàn bộ caption sinh ra trên 800 ảnh kiểm thử.
 - **Avg tokens/ảnh:** Số token trung bình trên mỗi ảnh, phản ánh độ dài điển hình của caption sinh ra.
 - **Ratio:** Tỷ lệ giữa tổng tokens sinh ra và tổng tokens tham chiếu. $\text{Ratio} > 1$ nghĩa là mô hình sinh caption dài hơn tham chiếu, $\text{ratio} < 1$ nghĩa là ngắn hơn, và $\text{ratio} \approx 1$ là lý tưởng nhất.
- **Chất lượng caption (Quality Metrics):** Sử dụng các độ đo chuyên biệt cho bài toán sinh văn bản (được tính sau khi tách từ tiếng Việt bằng thư viện `pyvi`):
 - **BLEU-1 đến BLEU-4:** Đo mức độ trùng khớp n-gram giữa câu sinh ra và các câu tham chiếu. BLEU-1 phản ánh độ phủ từ vựng đơn lẻ, trong khi BLEU-4 đánh giá tính mạch lạc của cụm từ dài hơn.
 - **CIDEr:** Đo mức độ tương đồng ngữ nghĩa giữa caption sinh ra và tập tham chiếu, có tính đến trọng số TF-IDF để ưu tiên các từ mang thông tin đặc trưng.
 - **ROUGE-L:** Đo độ dài chuỗi con chung dài nhất (Longest Common Subsequence) giữa câu sinh ra và câu tham chiếu, phản ánh khả năng bảo toàn cấu trúc câu.
- **Hiệu quả tài nguyên (Efficiency Metrics):** Đánh giá chi phí tính toán của từng mô hình:
 - **Params (M):** Tổng số tham số của mô hình, phản ánh độ phức tạp kiến trúc.
 - **Disk (GB):** Dung lượng lưu trữ cần thiết để tải mô hình.
 - **VRAM (GB):** Bộ nhớ GPU đỉnh tiêu thụ trong quá trình inference.
 - **Time/Img (s):** Thời gian suy diễn trung bình trên mỗi ảnh, phản ánh tốc độ xử lý thực tế.

Mô hình	Tổng tokens	Avg tokens/ảnh	Ratio
Vintern-1B-v3_5	37,590	46.99	1.36
Qwen2-VL-2B	31,694	39.62	1.18
BLIP-2	18,967	23.71	0.80

Bảng 2: Tổng số tokens và độ dài caption trung bình mỗi ảnh trên tập test (800 ảnh)

Mô hình	BLEU-1	BLEU-2	BLEU-3	BLEU-4	CIDEr	ROUGE-L
Vintern-1B-v3_5	36.49	15.73	7.62	3.98	3.89	17.66
Qwen2-VL-2B	37.94	16.48	7.26	3.13	4.52	17.66
BLIP-2	23.84	10.03	5.19	2.67	4.52	13.56

Bảng 3: So sánh chất lượng caption giữa các mô hình trên tập test (800 ảnh)

Mô hình	Params (M)	Disk (GB)	VRAM (GB)	Time/Img (s)
Vintern-1B-v3_5	938.19	3.50	2.30	4.40
Qwen2-VL-2B	2210.00	4.13	4.23	2.81
BLIP-2	3942.45	14.69	4.18	5.58

Bảng 4: So sánh hiệu quả tài nguyên giữa các mô hình

Dựa trên kết quả tổng hợp, nhóm nhận thấy **Qwen2-VL-2B** là lựa chọn tốt nhất để tiến hành fine-tune vì các lý do sau:

- **BLIP-2 bị loại do chất lượng tiếng Việt kém:** Mặc dù CIDEr của BLIP-2 bằng Qwen2-VL (4.52), mô hình này thua rõ rệt ở BLEU-1 (23.84) và ROUGE-L (13.56) – thấp hơn đáng kể so với hai mô hình còn lại. Thêm vào đó, BLIP-2 có ratio = 0.80, tức caption sinh ra ngắn hơn tham chiếu 20%, cho thấy mô hình bỏ sót nhiều thông tin quan trọng. Ngoài ra, BLIP-2 có số tham số lớn nhất (3942M) và dung lượng nặng nhất (14.69 GB), chi phí tài nguyên cao nhưng không mang lại lợi thế tương xứng trên dữ liệu tiếng Việt.
- **Cân bằng tốt nhất giữa các chỉ số chất lượng:** Qwen2-VL-2B dẫn đầu ở BLEU-1 (37.94), BLEU-2 (16.48), CIDEr (4.52) và ROUGE-L (17.66). Mặc dù Vintern-1B-v3_5 có BLEU-3 (7.62) và BLEU-4 (3.98) cao hơn, đây là các chỉ số đo khớp cụm từ dài và thường bị ảnh hưởng bởi độ dài caption – Vintern sinh trung bình 46.99 tokens/ảnh với ratio = 1.36, dài hơn tham chiếu tới 36%, khiến xác suất khớp n -gram dài tăng một cách tự nhiên. Trong khi đó, Qwen2-VL-2B sinh 39.62 tokens/ảnh với ratio = 1.18, gần với tham chiếu hơn và phản ánh khả năng sinh caption cân đối, tự nhiên hơn.
- **Vintern-1B-v3_5 xếp thứ hai:** Dù nhỏ gọn hơn (938M tham số) và có BLEU-3/BLEU-4 cao hơn,

Vintern thua Qwen ở các chỉ số phản ánh độ phủ tổng thể (BLEU-1, BLEU-2, CIDEr). Kết quả này cho thấy việc chuyên biệt hóa ngôn ngữ tiếng Việt chưa đủ để bù đắp cho kiến trúc đa ngôn ngữ mạnh hơn của Qwen2-VL trong bài toán sinh caption hỗ trợ người khiếm thị.


- **Tốc độ xử lý nhanh hơn:** Qwen2-VL-2B có thời gian suy diễn 2.81 s/ảnh, nhanh hơn Vintern (4.40 s) và BLIP-2 (5.58 s), là lợi thế thực tế khi fine-tune trên tập huấn luyện lớn.

Từ các phân tích toàn diện trên, nhóm quyết định chọn kiến trúc **Qwen2-VL-2B-Instruct** làm mô hình cốt lõi để huấn luyện chuyên sâu (fine-tune) trong giai đoạn tiếp theo.

3.2.2 Kiến trúc chi tiết các mô hình thử nghiệm


Dưới đây là sơ đồ và mô tả chi tiết về cấu trúc của ba mô hình đã trải qua giai đoạn thử nghiệm:

1. Mô hình BLIP2-Flan-T5-XL: Kiến trúc này sử dụng bộ kết nối **Q-Former** để thu hẹp khoảng cách giữa Vision Encoder (ViT) và Language Model (Flan-T5). Q-Former trích xuất một số lượng cố định các visual tokens bất kể độ phân giải ảnh đầu vào, giúp tối ưu chi phí tính toán nhưng có thể làm mất chi tiết nhỏ.



Hình 7: Sơ đồ kiến trúc tổng quát của mô hình BLIP-2.


2. Mô hình Vintern-1B-v3_5: Được tối ưu riêng cho tiếng Việt, mô hình này kết hợp **InternViT-300M** và **Qwen2-0.5B**. Điểm mạnh là cơ chế *Dynamic Resolution*, cho phép chia ảnh gốc thành tối đa 6 tiles kích thước 448×448 để xử lý chi tiết cao.



Hình 8: Sơ đồ kiến trúc tổng quát của Vintern-1B-v3_5.

3. Mô hình Qwen2-VL-2B-Instruct (Mô hình lựa chọn): Kiến trúc này đại diện cho thể hệ mô hình thị giác-ngôn ngữ mới nhất với các thành phần:

- **Vision Encoder (675M):** Sử dụng ViT hỗ trợ *Naive Dynamic Resolution*, cho phép mô hình tiếp nhận ảnh ở độ phân giải gốc, giúp nhận diện vật cản nhỏ ở khoảng cách xa.
- **M-RoPE (Multimodal Rotary Position Embedding):** Phân rã thông tin vị trí thành các thành phần thời gian, chiều cao và chiều rộng. Điều này giúp mô hình hiểu rõ vị trí tương đối (trái/phải) của vật cản so với người dùng.
- **Language Decoder (1.5B):** Dựa trên kiến trúc Qwen2, được huấn luyện theo hướng *instruction tuning* để phản hồi chính xác các yêu cầu hỗ trợ định hướng.



Hình 9: Sơ đồ kiến trúc tổng quát của hệ thống Qwen2-VL-2B-Instruct.

3.3 Cấu hình Huấn luyện

Để tối ưu hóa mô hình Qwen2-VL-2B-Instruct trên bộ dữ liệu 8.000 mẫu, nhóm đã thiết lập cấu hình huấn luyện chi tiết tập trung vào tính hội tụ và hiệu quả tài nguyên.

3.3.1 Hàm mất mát và Thuật toán tối ưu

- Hàm mất mát (Loss Function):** Nhóm sử dụng **Cross-Entropy Loss** làm hàm mục tiêu chính. Đây là lựa chọn tiêu chuẩn cho các bài toán sinh ngôn ngữ tự nhiên (Next Token Prediction), giúp đo lường sự khác biệt giữa phân phối xác suất của token dự đoán và nhãn thực tế, từ đó ép mô hình sinh ra các câu chú thích bám sát phong cách và nội dung của dữ liệu huấn luyện.
- Thuật toán tối ưu (Optimizer):** Sử dụng thuật toán **AdamW** (Adam with Weight Decay). Thuật toán này giúp xử lý tốt các đạo hàm thưa và tích hợp cơ chế Weight Decay để hạn chế hiện tượng quá khớp (overfitting), giúp mô hình duy trì khả năng tổng quát hóa sau khi huấn luyện.
- Chiến lược tốc độ học (Learning Rate Strategy):** Nhóm sử dụng bộ lập lịch *Cosine Annealing* kết hợp với *Warmup ratio* 10%. Tốc độ học tăng dần ở giai đoạn đầu để ổn định trọng số, sau đó giảm dần theo đường cong cosine để hội tụ sâu ở giai đoạn cuối.

3.3.2 Bảng tổng hợp siêu tham số (Hyperparameters)

Quá trình huấn luyện được thực hiện bằng kỹ thuật **PEFT-LoRA** nhằm tối ưu hóa bộ nhớ GPU, chỉ cập nhật khoảng 0.8% tham số của toàn bộ mô hình.

Bảng 5: Các siêu tham số chính trong quá trình huấn luyện mô hình

Siêu tham số	Giá trị thiết lập
Cấu hình GPU	01 $\times$ NVIDIA A100 (80GB VRAM)
Kiểu dữ liệu (Precision)	bfloat16 (BF16)
LoRA Rank (r)	16
LoRA Alpha	32
Batch Size	16 (với Gradient Accumulation = 1)
Trọng số suy giảm (Weight Decay)	0.01
Giai đoạn huấn luyện chính (Epoch 1-2)	Learning rate = 1×10^{-4}
Giai đoạn tinh chỉnh (Epoch 3)	Learning rate = 2×10^{-5}

3.3.3 Phương pháp tinh chỉnh tham số

Thay vì sử dụng các phương pháp tự động tốn kém tài nguyên như Grid Search hay Random Search, nhóm áp dụng phương pháp **Tinh chỉnh thủ công (Manual Tuning)** dựa trên quan sát thực nghiệm:


1. **Thử nghiệm Zero-shot:** Đánh giá năng lực ban đầu của mô hình gốc để xác định mức Baseline.
2. **Thử nghiệm Batch Size:** Nhóm đã thực hiện thử nghiệm với các giá trị batch size khác nhau (8, 16, 32) trên GPU A100 để tìm ra mức tối ưu giúp ổn định gradient mà không gây tràn bộ nhớ.
3. **Chiến lược huấn luyện hai giai đoạn:** Qua quan sát xu hướng *Validation Loss* sau Epoch 2, nhóm quyết định thực hiện thêm Epoch 3 (Polishing) với tốc độ học giảm 5 lần so với ban đầu. Việc này giúp mô hình "đánh bóng" kết quả, giảm thiểu các lỗi nhỏ về ngữ pháp và tăng tính mạch lạc cho câu văn.
4. **Lựa chọn Checkpoint:** Sử dụng tùy chọn `load_best_model_at_end` để tự động lựa chọn và lưu trữ trạng thái mô hình tại bước có Validation Loss thấp nhất, thay vì lấy checkpoint cuối cùng một cách máy móc.

4 Kết quả và Thảo luận

4.1 Kết quả Thực nghiệm

4.1.1 Biểu đồ quá trình học (Learning Curves)

Quá trình huấn luyện mô hình Qwen2-VL-2B-Instruct được thực hiện qua 6.000 bước (steps). Nhóm theo dõi sự hội tụ thông qua giá trị Loss trên tập Train và Validation.




Hình 10: Biểu đồ hội tụ Loss của mô hình Qwen2-VL qua 6.000 bước huấn luyện

Nhận xét (Hình 10): Mô hình đạt trạng thái hội tụ lý tưởng. Đường Validation Loss bám sát đường Training Loss với khoảng cách hẹp (0.05–0.15), cho thấy mô hình học được đặc trưng tốt mà không bị Underfitting hay Overfitting nghiêm trọng.

4.1.2 Đánh giá hiệu năng trên tập Validation

Để quan sát sự phát triển năng lực ngôn ngữ, nhóm thực hiện đánh giá tại các mốc hoàn thành từng Epoch dựa trên hai chỉ số quan trọng là CIDEr và ROUGE-L.

Nhận xét (Hình 11): Chỉ số CIDEr đạt đỉnh tại Epoch 2 (46.60) sau đó giảm nhẹ ở Epoch 3. Điều này cho thấy Epoch 2 là điểm tối ưu nhất để lựa chọn checkpoint triển khai.



Hình 11: Biến thiên của chỉ số CIDEr và ROUGE-L trên tập Validation qua các mốc huấn luyện

4.1.3 Kết quả tổng thể trên tập Test

Dưới đây là bảng so sánh hiệu năng giữa mô hình gốc (Base) và mô hình sau khi fine-tune (Finetuned) trên tập dữ liệu kiểm tra độc lập.

Bảng 6: So sánh các chỉ số chất lượng ngôn ngữ giữa mô hình gốc và sau khi Fine-tuning

Mô hình	CIDEr	BLEU-1	BLEU-4	ROUGE-L
Qwen2-VL-Base	4.52	37.94	3.13	17.66
Qwen2-VL-Finetuned	47.52	67.41	24.69	39.56

4.2 Thảo luận và Phân tích lỗi

4.2.1 Hiện tượng Overfitting và Underfitting

Dựa trên các biểu đồ thực nghiệm, nhóm rút ra các nhận định:

- **Hội tụ lý tưởng:** Cấu hình Learning Rate 10^{-4} và kỹ thuật LoRA giúp mô hình đạt trạng thái "Good fit".
- **Overfitting nhẹ:** Xuất hiện tại Epoch 3 khi Loss tiếp tục giảm nhưng CIDEr trên tập Test giảm từ 47.52 xuống 46.22. Đây là dấu hiệu mô hình bắt đầu tối ưu hóa quá mức theo tập huấn luyện. Nhóm đã khắc phục bằng cách chọn checkpoint tại bước 4.000.

4.2.2 Phân tích các trường hợp sai và hạn chế

Nhóm nhận diện được 3 nhóm lỗi chính thông qua quan sát kết quả dự đoán thực tế:

1. Lỗi cắt câu (Truncation Error):

- Ví dụ: Ảnh 00249.jpg dự đoán: "...bạn chú ý r".
- Giả thuyết: Do mô hình cố gắng sinh câu dài nhưng vượt quá giới hạn `max_new_tokens`, hoặc cơ chế dừng (EOS token) bị nhiễu.

2. Lỗi khuôn mẫu hóa (Templating/Repetitiveness):

- Ví dụ: Một nhóm khoảng 15 ảnh đường phố (00048, 00061, 00222, ...) lặp lại cụm: *'lòng đường trải nhựa phẳng lỳ'*.
- Giả thuyết: Do sự mất cân bằng trong dữ liệu huấn luyện, mô hình có xu hướng học các mẫu câu phổ biến (template bias) và lặp lại chúng cho nhiều trường hợp tương tự thay vì mô tả chi tiết riêng biệt.

3. Lỗi bỏ sót thực thể quan trọng (Missing Objects): Mô hình đôi khi bị thu hút bởi các vật thể lớn và bỏ qua thực thể nhỏ quan trọng ở gần.



Hình 12: Mô hình bỏ sót thực thể đứa trẻ ở cự ly gần.

- Ví dụ hình 12: *"Phía trước là bụi sân đỗ xe có chiếc xe buýt màu vàng đang mở cửa với bậc thang dẫn lên, bạn hãy khua gậy cẩn thận để tìm lối đi vòng qua an toàn khỏi khu vực này."*

Câu trên hoàn toàn thiếu cảnh báo về đứa trẻ trước mặt.

- *Giả thuyết:* Đặc trưng thị giác mạnh của chiếc xe buýt màu vàng chiếm ưu thế lớn trong ảnh so với đứa trẻ, hoặc do dataset nhóm xây dựng đa phần nội dung chính là vật thể, phương tiện, quá ít ảnh có người làm nội dung chủ đạo, nên mô hình vô tình không học được cách cảnh báo về con người.

4. **Lỗi lan man và chi tiết thừa (Redundant Info):** Mô hình mô tả các chi tiết quá xa không cần thiết cho việc di chuyển an toàn.



Hình 13: Mô hình liệt kê các chi tiết ở quá xa không cần thiết.

- Ví dụ hình 13: "*Ở gần mép phải là mặt quầy đá hoa cương lấp đầy không gian, vách trái có tủ bếp gỗ sáng màu, xa trước mặt là cửa kính lớn, hãy chú ý lách người đi dọc khe hở giữa phòng để tránh va đập.*"

Việc mô tả cả cửa sổ ở xa là không cần thiết.

- *Giả thuyết:* Mô hình chưa học được cách ưu tiên thông tin theo mức độ quan trọng. Việc mô tả "cửa kính lớn" ở quá xa gây nhiễu cho người khiếm thị vốn chỉ cần tập trung vào việc lách qua lối đi hẹp trong bếp.

Tổng kết thảo luận: Mô hình đã đạt được mục tiêu đề ra với khả năng sinh chú thích tiếng Việt mạch lạc. Mặc dù còn tồn tại một số hạn chế về mặt thị giác (attention bias), nhưng kết quả CIDEr tăng trưởng mạnh mẽ chứng minh cho sự thành công của quá trình huấn luyện chuyên biệt cho người khiếm thị.

5 Xây dựng và Triển khai Ứng dụng

Sau khi hoàn tất quá trình lựa chọn, fine-tune và đánh giá mô hình, nhóm tiến hành xây dựng một ứng dụng web nhằm kiểm chứng khả năng ứng dụng thực tế của hệ thống Image Captioning tiếng Việt hỗ trợ người khiếm thị. Mục tiêu của giai đoạn này không chỉ là đưa mô hình vào sử dụng, mà còn thiết kế một luồng tương tác đơn giản, dễ thao tác và phù hợp với người dùng có hạn chế về thị giác.

Ứng dụng được triển khai dưới dạng web app, có thể chạy trực tiếp trên trình duyệt điện thoại mà không cần cài đặt thêm phần mềm. Người dùng chỉ cần mở đường dẫn ứng dụng, cấp quyền truy cập camera và chạm hai lần vào màn hình để chụp ảnh bối cảnh phía trước. Ảnh sau đó được gửi đến máy chủ AI để mô hình phân tích và sinh ra một câu mô tả tiếng Việt kèm hướng dẫn di chuyển an toàn. Kết quả được hiển thị trên giao diện và đồng thời được đọc tự động bằng giọng nói thông qua cơ chế Text-to-Speech của trình duyệt.

5.1 Kiến trúc tổng thể của hệ thống

Hệ thống được thiết kế theo mô hình client-server, trong đó frontend đảm nhiệm việc tương tác với người dùng, còn backend đảm nhiệm việc xử lý ảnh và suy diễn mô hình. Kiến trúc tổng thể gồm ba thành phần chính:

- **Frontend:** Ứng dụng web được xây dựng bằng React, tối ưu cho trình duyệt điện thoại. Frontend có nhiệm vụ mở camera, chụp ảnh, cho phép tải ảnh lên để phục vụ demo, gửi ảnh đến backend, nhận kết quả mô tả và đọc kết quả bằng âm thanh.
- **Backend:** Máy chủ AI được xây dựng bằng Python và FastAPI, chạy trên môi trường Google Colab. Backend nhận ảnh từ frontend thông qua API, tiền xử lý ảnh, đưa ảnh vào mô hình Qwen2-VL-2B-Instruct đã fine-tune, sau đó trả về chuỗi caption tiếng Việt cùng thời gian xử lý.
- **Mô hình AI:** Hệ thống sử dụng checkpoint fine-tuned của Qwen2-VL-2B-Instruct. Đây là mô hình đã được huấn luyện chuyên biệt trên bộ dữ liệu của nhóm để sinh chú thích theo cấu trúc: mô tả bối cảnh, nhận diện vật cản chính và đưa ra chỉ dẫn an toàn.

Do backend được chạy trên Google Colab, nhóm sử dụng Ngrok để tạo một public URL cho API. Nhờ đó, frontend được deploy trên Netlify vẫn có thể gửi ảnh đến mô hình đang chạy trong môi trường Colab. Cách triển khai này phù hợp với phạm vi đồ án vì tận dụng được GPU của Colab, dễ trình diễn trong buổi báo cáo và không yêu cầu thuê server GPU riêng.

5.2 Luồng hoạt động của ứng dụng

Luồng xử lý của ứng dụng được thiết kế ngắn gọn nhằm giảm tối đa số thao tác thủ công cho người dùng như mô tả sau:

1. **Khởi động ứng dụng:** Người dùng mở đường dẫn web app trên trình duyệt. Màn hình đầu tiên hiển thị nút *Bắt đầu* với kích thước lớn, dễ thao tác. Khi người dùng chạm vào màn hình, ứng dụng khởi tạo âm thanh và hướng dẫn người dùng cấp quyền camera.
2. **Mở camera:** Sau khi được cấp quyền, ứng dụng mở camera sau của điện thoại bằng API `getUserMedia`. Ứng dụng phát hướng dẫn bằng giọng nói: “Đã bật máy ảnh. Hãy chạm hai lần vào bất kỳ đâu trên màn hình để chụp.”
3. **Chụp hoặc tải ảnh:** Người dùng có thể chạm hai lần vào màn hình để chụp ảnh trực tiếp từ camera. Ngoài ra, ứng dụng cũng cung cấp nút upload ảnh để thuận tiện cho quá trình demo và kiểm thử với các ảnh có sẵn.
4. **Gửi ảnh đến backend:** Ảnh được chuyển thành định dạng JPEG hoặc giữ nguyên file gốc khi upload, sau đó được gửi đến API `/predict` bằng phương thức `POST`. Dữ liệu ảnh được truyền dưới dạng `FormData`, giúp backend có thể nhận trực tiếp file ảnh thay vì phải giải mã chuỗi Base64.
5. **Suy diễn mô hình:** Backend nhận ảnh, kiểm tra định dạng file, resize ảnh về kích thước phù hợp, sau đó đưa ảnh vào mô hình Qwen2-VL-2B-Instruct đã fine-tune. Prompt được sử dụng yêu cầu mô hình sinh đúng một câu tiếng Việt ngắn, mô tả vật thể hoặc chương ngại chính và đưa ra hướng dẫn di chuyển an toàn.
6. **Trả kết quả:** Backend trả về kết quả dưới dạng JSON, bao gồm trạng thái xử lý, caption tiếng Việt và thời gian suy diễn. Frontend nhận caption, hiển thị trong khung kết quả và tự động đọc to bằng Text-to-Speech.

Luồng xử lý trên giúp ứng dụng hoạt động gần với một trợ lý thị giác: người dùng chỉ cần hướng camera về phía trước, chạm hai lần để chụp và nghe mô tả tình huống ngay sau khi hệ thống xử lý xong.

5.3 Triển khai backend

Backend được xây dựng bằng FastAPI do framework này nhẹ, dễ triển khai API và phù hợp với các mô hình học sâu chạy bằng Python. Các thư viện chính được sử dụng gồm `transformers`, `torch`, `qwen-vl-utils`, `Pillow`, `FastAPI`, `uvicorn` và `pyngrok`.

Mô hình được nạp từ checkpoint fine-tuned của nhóm:

pgthinh232/HCMUS-Qwen2-VL-2B-Instruct-Vietnamese-Image-Captioning-for-blind-E2

Để đảm bảo chất lượng suy diễn, backend sử dụng mô hình ở kiểu dữ liệu `float16` và tự động ánh xạ thiết bị bằng `device_map="auto"`. Ảnh đầu vào được chuyển sang RGB, sau đó resize sao cho cạnh lớn không vượt quá 768 pixel. Bước resize này giúp giảm chi phí tính toán, đồng thời vẫn giữ được các thông tin thị giác quan trọng phục vụ nhận diện vật cản.

API chính của backend là endpoint `/predict`. Endpoint này nhận một file ảnh, kiểm tra kiểu dữ liệu, xử lý ảnh, gọi hàm sinh caption và trả về kết quả theo cấu trúc:

```
{
  "success": true,
  "caption": "...",
  "latency_seconds": 2.001
}
```

Ngoài endpoint dự đoán, backend còn cung cấp endpoint `/health` để kiểm tra trạng thái hoạt động của server, thiết bị CUDA và việc nạp mô hình. Việc này giúp nhóm dễ kiểm tra backend trước khi kết nối với frontend.

5.4 Triển khai frontend

Frontend được xây dựng bằng React và deploy trên Netlify tại đường dẫn:

<https://blind-assistant-ml.netlify.app/>

Giao diện được thiết kế theo hướng tối giản, ưu tiên trải nghiệm của người khiếm thị. Ứng dụng sử dụng nền đen toàn màn hình, chữ lớn, nút bấm lớn, độ tương phản cao và hạn chế tối đa các thành phần gây nhiễu. File CSS cấu hình chiều cao và chiều rộng toàn màn hình, tắt cuộn trang và dùng `touch-action: manipulation` để hạn chế thao tác zoom không mong muốn trên điện thoại.


Các chức năng chính của frontend gồm:

- **Màn hình bắt đầu:** Hiển thị nút *Bắt đầu* kích thước lớn, giúp người dùng dễ kích hoạt ứng dụng.
- **Camera trực tiếp:** Sử dụng camera sau của điện thoại để mô phỏng góc nhìn của người dùng khi di chuyển.
- **Chụp ảnh bằng chạm hai lần:** Ứng dụng nhận diện hai lần chạm liên tiếp trong khoảng thời gian ngắn để kích hoạt chụp ảnh. Cách này giúp giảm nhầm lẫn so với việc phải tìm một nút nhỏ trên màn hình.

- **Upload ảnh:** Cho phép tải ảnh từ thiết bị để phục vụ kiểm thử, thuyết trình và demo trong trường hợp không muốn dùng camera trực tiếp.
- **Khung hiển thị kết quả:** Caption được hiển thị trong một khung lớn, nền đen, viền vàng, chữ trắng lớn. Người dùng có thể chạm vào khung này để nghe lại kết quả.
- **Cài đặt API:** Ứng dụng cho phép nhập và lưu backend API URL vào `localStorage`. Điều này hữu ích vì URL Ngrok có thể thay đổi sau mỗi lần khởi động lại backend trên Colab.
- **Mã QR:** Giao diện cài đặt có chức năng tạo mã QR từ đường dẫn hiện tại, giúp người dùng hoặc giảng viên có thể quét và mở ứng dụng nhanh trên điện thoại.



Hình 14: Giao diện camera sau khi người dùng khởi động ứng dụng.



Hình 15: Giao diện hiển thị kết quả mô tả và hướng dẫn an toàn sau khi mô hình xử lý ảnh.

5.5 Kết quả triển khai thực tế

Trong quá trình kiểm thử, ứng dụng đã chạy được trên trình duyệt điện thoại thông qua đường dẫn Netlify. Khi mở ứng dụng, người dùng thấy màn hình bắt đầu, sau đó ứng dụng yêu cầu quyền camera và phát hướng dẫn bằng giọng nói. Sau khi chạm hai lần để chụp ảnh, frontend gửi ảnh đến backend, hiển thị trạng thái *Đang phân tích...*, sau đó nhận và đọc kết quả mô tả.

Ví dụ với ảnh đường phố như hình ở trên, hệ thống trả về kết quả:

“lòng đường phía trước tấp nập xe máy đang lưu thông dưới nắng, vỉa hè bên phải trước cửa hàng thuốc có nhiều ô dù che nắng nên bạn hãy đi sát vào mép ngoài”

Kết quả này cho thấy mô hình đã nhận diện được vật cản chính trong ảnh và sinh ra hướng dẫn di chuyển an toàn bằng tiếng Việt. Thời gian xử lý trong lần kiểm thử minh họa đạt khoảng 2 giây, phù hợp cho mục tiêu trình diễn và đánh giá khả năng ứng dụng thực tế của hệ thống.

6 Kết luận

Đồ án đã hoàn thành mục tiêu xây dựng một mô hình AI đa phương thức, có khả năng sinh chú thích ảnh tiếng Việt mang tính định hướng hành động cao, hỗ trợ đắc lực cho người khiếm thị.

Kết quả đạt được:

- **Dữ liệu chuyên biệt:** Xây dựng thành công bộ dữ liệu 8.000 cặp ảnh - chú thích. Cấu trúc nhân được thiết kế tối ưu (vị trí + chướng ngại vật + chỉ dẫn an toàn), khắc phục điểm yếu của các dữ liệu miêu tả thông thường.
- **Tối ưu hóa mô hình:** Việc lựa chọn và fine-tune kiến trúc Qwen2-VL-2B bằng PEFT-LoRA đã mang lại sự bứt phá: chỉ số CIDEr tăng gấp 10 lần (từ 4.52 lên 47.52), chứng minh mô hình đã học được chính xác bối cảnh và văn phong dẫn đường.

Hạn chế còn tồn tại:

Dù đạt kết quả định lượng tốt, mô hình vẫn gặp một số giới hạn đặc thù như: lỗi khuôn mẫu hóa (lặp cụm từ phổ biến), miêu tả chi tiết thừa ở xa, hoặc bỏ sót vật thể nhỏ ở gần (trẻ em, vật cản thấp) do sự phân bổ chú ý (attention bias) chưa hoàn hảo.

Hướng phát triển tương lai:

1. **Cải thiện dữ liệu và Tối ưu hóa bằng DPO:** Bổ sung hình ảnh chứa "người" và "vật cản tầm thấp" vào tập huấn luyện. Để khắc phục triệt để lỗi miêu tả lan man, nhóm đề xuất áp dụng thuật toán **DPO (Direct Preference Optimization)** kết hợp cơ chế chấm điểm tự động bằng mô hình ngôn ngữ lớn (RLAIF). Phương pháp này giúp ép mô hình học được cách ưu tiên cảnh báo các chướng ngại vật nguy hiểm ở cự ly gần.
2. **Triển khai Edge AI:** Nghiên cứu kỹ thuật lượng tử hóa (Quantization) để nén và đưa mô hình chạy trực tiếp (offline) trên điện thoại di động. Việc này giúp ứng dụng phản hồi tức thời (real-time) ngay cả khi không có mạng Internet, đảm bảo an toàn tối đa cho người dùng.
3. **Xử lý chuỗi hình ảnh liên tục (Video Stream):** Nâng cấp hệ thống từ việc phân tích ảnh tĩnh sang xử lý luồng video theo thời gian thực. Việc hiểu được sự dịch chuyển của bối cảnh và hướng đi của các phương tiện giao thông sẽ giúp mô hình đưa ra các cảnh báo động (dynamic warnings) chính xác hơn.

Tài liệu

- [1] 5CD-AI. Vintern-1b-v3_5. https://huggingface.co/5CD-AI/Vintern-1B-v3_5, 2024.
- [2] K. T. Doan, , et al. Vintern-1b: An efficient multimodal large language model for vietnamese. *arXiv preprint arXiv:2408.12480*, 2024.
- [3] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. *arXiv preprint arXiv:2201.12086*, 2022.
- [4] Tsung-Yi Lin, , et al. Microsoft coco: Common objects in context. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 740–755. Springer, 2014.
- [5] Perceval-Wilhelm. Image-captioning-convert-to-vietnamese. <https://github.com/Perceval-Wilhelm/Image-captioning-convert-to-Vietnamese>, 2023.
- [6] Salesforce. Blip2-flan-t5-xl. <https://huggingface.co/Salesforce/blip2-flan-t5-xl>, 2023.
- [7] Qwen Team. Qwen2-vl-2b-instruct. <https://huggingface.co/Qwen/Qwen2-VL-2B-Instruct>, 2024.
- [8] J. Wang, , et al. Git: A generative image-to-text transformer for vision and language. *arXiv preprint arXiv:2205.14100*, 2022.
- [9] Peng Wang, , et al. Qwen2-vl: Enhancing vision-language model’s perception of the world at any resolution. *arXiv preprint arXiv:2409.12191*, 2024.